# Dari Kecerdasan Buatan Spesifik Menuju Kecerdasan Super yang Aman: Pengambilan Keputusan Adaptif dan Dapat Digeneralisasi pada Sistem Sinyal Lalu Lintas

Muhamad Faza Almaliki
Program Studi Doktor Informatika, Universitas Hasanuddin, Gowa, Indonesia

**Abstrak** - Makalah ini menganalisis kemungkinan perkembangan Artificial Intelligence menuju Artificial Superintelligence (ASI) dalam dua puluh tahun serta prasyarat keselamatannya. Pendekatan yang digunakan meliputi kajian literatur, analisis teknis AlphaDev, dan eksperimen alignment pada dua model bahasa menggunakan 50 pertanyaan. Hasil studi kasus menunjukkan bahwa AlphaDev mampu menemukan algoritma yang lebih efisien pada domain tertentu, tetapi belum menunjukkan kecerdasan lintas domain. Evaluasi jawaban akhir menghasilkan akurasi 92% dan 100%, dengan hasil uji McNemar exact p = 0,125 yang menunjukkan bahwa perbedaan tersebut belum signifikan secara statistik. Pengamatan perubahan jawaban memberikan indikasi awal sikofansi, sedangkan kalibrasi keyakinan, specification gaming, dan konsistensi nilai masih memerlukan pengujian tersendiri. Temuan ini menegaskan pentingnya pengukuran keandalan, pengawasan manusia, dan pembatasan tindakan dalam pengembangan AI yang semakin otonom.

**Kata Kunci: Artificial Superintelligence, AlphaDev, AI Alignment, Sikofansi, Reinforcement Learning.**

## I. PENDAHULUAN

Perkembangan *Artificial Intelligence* (AI) menunjukkan pergeseran dari sistem yang dirancang untuk menyelesaikan tugas spesifik menuju sistem yang mampu melakukan penalaran, menghasilkan algoritma, serta mengambil keputusan pada berbagai kondisi. Perkembangan tersebut memunculkan kembali pertanyaan mengenai kemungkinan tercapainya *Artificial Superintelligence* (ASI), yaitu kecerdasan mesin yang secara luas melampaui kemampuan intelektual manusia. Makalah ini mengambil posisi bahwa ASI mungkin terwujud dalam dua puluh tahun mendatang, sekitar tahun 2046. Namun, pencapaiannya tidak dapat dianggap sebagai konsekuensi otomatis dari perkembangan AI saat ini. Posisi tersebut didukung oleh tiga argumen utama, yaitu peningkatan kemampuan melalui scaling dan efisiensi komputasi, berkembangnya kemampuan AI untuk membantu penemuan algoritma, serta meningkatnya kemampuan adaptasi dan generalisasi pada lingkungan yang kompleks.

Argumen pertama didasarkan pada perkembangan *scaling* dan efisiensi model AI. Penelitian [1] menganalisis 809 model bahasa yang dirilis pada 2022–2025 dan menemukan bahwa sekitar 80–90% perbedaan performa pada model *frontier* dapat dijelaskan oleh peningkatan komputasi pelatihan. Penelitian tersebut juga menunjukkan bahwa kemajuan algoritmik dan efisiensi pengembang berkontribusi terhadap kemampuan model yang lebih kecil untuk mencapai tingkat performa tertentu. Temuan ini diperkuat [2] yang memperkenalkan konsep *densing law* berdasarkan analisis terhadap 51 model bahasa *open-source*. Hasilnya menunjukkan bahwa kepadatan kemampuan model terbaik meningkat secara eksponensial, dengan waktu penggandaan sekitar 3,5 bulan berdasarkan *benchmark* yang digunakan. Kedua penelitian tersebut memperlihatkan bahwa peningkatan kemampuan AI dapat berlangsung melalui pertumbuhan komputasi dan efisiensi arsitektur. Walaupun tren tersebut tidak membuktikan bahwa ASI pasti muncul, hasilnya memberikan bukti bahwa jalur peningkatan kemampuan AI masih berkembang.

Argumen kedua berkaitan dengan kemampuan AI untuk menghasilkan solusi algoritmik baru yang dapat dievaluasi secara sistematis. Penelitian [3] memperkenalkan FunSearch, yaitu sistem yang menggabungkan *Large Language Model* dengan mekanisme pencarian evolusioner dan evaluator otomatis. Penelitian tersebut menunjukkan bahwa FunSearch mampu menemukan konstruksi baru pada *cap set problem* serta menghasilkan heuristik yang meningkatkan kinerja penyelesaian *online bin packing*. Hasil ini penting karena AI mulai menunjukkan kemampuan untuk membantu proses penemuan ilmiah dan perancangan algoritma, bukan sekadar mengenali pola dalam data. Perkembangan tersebut memiliki hubungan konseptual dengan gagasan *intelligence explosion*, ketika peningkatan

kemampuan AI berpotensi mempercepat pengembangan sistem AI berikutnya. Meskipun FunSearch belum membuktikan adanya *recursive self-improvement* yang mandiri, penelitian ini menunjukkan bahwa sebagian proses pencarian dan evaluasi algoritmik telah dapat diotomatisasi.

Argumen ketiga berhubungan dengan kemampuan generalisasi dalam lingkungan pengambilan keputusan yang dinamis. Dalam *Intelligent Transportation Systems* (ITS), khususnya *adaptive traffic signal control*, agen AI harus mampu menyesuaikan pengaturan sinyal terhadap perubahan volume kendaraan, distribusi arus, konfigurasi persimpangan, dan karakteristik jaringan jalan. Kemudian [4] mengembangkan *General Scenario-Agnostic Reinforcement Learning* (GESA), yaitu pendekatan yang memungkinkan satu agen mengendalikan berbagai konfigurasi persimpangan melalui representasi state dan action yang seragam. Model tersebut dilatih menggunakan tujuh skenario dan menghasilkan peningkatan *reward* sebesar 13,27% dibandingkan metode pembanding. Pada pengujian skenario baru, GESA juga menunjukkan peningkatan *reward* sebesar 9,39%, sehingga memberikan bukti empiris mengenai kemampuan *zero-shot transfer*.

Hasil tersebut diperkuat oleh [5] melalui *Model-Based Graph Reinforcement Learning for Inductive Traffic Signal Control*. Penelitian ini memperkenalkan MuJAM untuk meningkatkan generalisasi terhadap struktur jaringan jalan, distribusi lalu lintas, dan batas pengendalian sinyal yang berbeda. Evaluasi menunjukkan kemampuan *zero-shot transfer* pada jaringan dan kondisi lalu lintas yang tidak digunakan selama pelatihan. Penelitian tersebut juga melakukan eksperimen transfer dalam simulasi yang melibatkan 3.971 traffic signal controllers di Manhattan. Kedua penelitian ini memperlihatkan bahwa generalisasi pada sistem pengambilan keputusan telah menjadi kemampuan yang dapat diuji secara empiris. Namun, kemampuan tersebut masih terbatas pada domain pengendalian lalu lintas dan belum dapat disamakan dengan kecerdasan umum maupun ASI.

Kemampuan adaptasi dan generalisasi juga perlu dikembangkan bersama mekanisme pengendalian tujuan. Studi [6] mengembangkan *Vehicle-Level Fairness-Oriented Constrained Multi-Agent Reinforcement Learning* untuk *adaptive traffic signal control*. Penelitian tersebut menggunakan *constrained reinforcement learning* untuk memperhatikan keadilan waktu tunggu kendaraan sambil mempertahankan efisiensi lalu lintas. Temuan ini menunjukkan bahwa keputusan agen AI dapat diarahkan melalui batas optimasi yang lebih terukur. Pendekatan tersebut relevan dengan pengembangan AI yang aman karena sistem tidak cukup hanya mengejar *reward* tertinggi. Sistem juga perlu mempertimbangkan batas tindakan, risiko, dan konsekuensi bagi pengguna. Namun, pemenuhan kendala *fairness* belum dengan sendirinya menjamin keselamatan fisik atau *alignment* yang menyeluruh.

Meskipun perkembangan tersebut mendukung kemungkinan kemunculan ASI, argumen lawan yang paling kuat menyatakan bahwa peningkatan kemampuan model tidak selalu menghasilkan peningkatan keandalan. Penelitian [7] menunjukkan bahwa model bahasa yang lebih besar dan semakin mudah mengikuti instruksi tidak selalu menjadi lebih dapat diandalkan. Dalam sejumlah kondisi, model yang lebih canggih justru menghasilkan jawaban yang tampak meyakinkan tetapi keliru. Penelitian [8] juga menunjukkan bahwa penggunaan data sintetis secara berulang tanpa pengendalian yang memadai dapat menyebabkan model *collapse*, yaitu penurunan kemampuan model dalam merepresentasikan distribusi data asli. Kedua hasil tersebut memperlihatkan bahwa *scaling*, penambahan data, dan peningkatan performa benchmark belum cukup untuk menjamin generalisasi dan reliability.

Tantangan lain ditemukan [9] melalui penelitian mengenai *emergent misalignment*. Penelitian tersebut menunjukkan bahwa *fine-tuning model* bahasa untuk tugas sempit, seperti menghasilkan kode yang tidak aman, dapat memunculkan perilaku tidak selaras pada konteks lain. Pada beberapa kondisi pengujian, respons yang tidak selaras ditemukan hingga sekitar 50% kasus. Hasil ini memperlihatkan bahwa peningkatan atau modifikasi kemampuan AI dapat menimbulkan konsekuensi yang tidak selalu dapat diprediksi dari tujuan pelatihannya. Dengan demikian, keberhasilan AI dalam menyelesaikan tugas tertentu tidak otomatis membuktikan bahwa sistem tersebut aman ketika diberi kewenangan mengambil keputusan yang lebih luas.

Argumen lawan tersebut memiliki dasar empiris yang kuat. Namun, keterbatasan *scaling*, generalisasi, dan *alignment* saat ini belum cukup untuk menyimpulkan bahwa ASI tidak mungkin terwujud dalam dua puluh tahun. Perkembangan AI tidak hanya ditentukan oleh satu pendekatan pelatihan. Peningkatan kemampuan dapat berasal dari kombinasi efisiensi algoritma, *reinforcement learning*, sistem berbasis agen, penggunaan alat eksternal, serta mekanisme evaluasi dan perbaikan yang semakin otomatis. Oleh karena itu, posisi yang lebih dapat dipertanggungjawabkan secara ilmiah adalah mengakui kemungkinan perkembangan menuju ASI sekaligus mempertahankan ketidakpastian mengenai waktu dan jalur pencapaiannya.

Prediksi para ahli memberikan perspektif tambahan terhadap persoalan tersebut. Penelitian [10] yang dipublikasikan pada 2025 melaporkan hasil survei terhadap 2.778 peneliti AI pada Oktober 2023. Hasil survei menunjukkan bahwa responden memperkirakan probabilitas 10% pada 2027 dan

50% pada 2047 untuk tercapainya kemampuan mesin tanpa bantuan manusia yang dapat mengungguli manusia pada setiap tugas, dengan asumsi perkembangan sains tidak mengalami gangguan besar.

Berdasarkan sisi metodologi, prediksi [10] mempunyai sejumlah keterbatasan. Pertama, hasil survei menggambarkan keyakinan responden dan bukan hasil eksperimen yang dapat memastikan waktu kemunculan kecerdasan tingkat lanjut. Kedua, perbedaan definisi mengenai kemampuan manusia, kecerdasan umum, dan superintelligence dapat memengaruhi interpretasi prediksi. Ketiga, prediksi jangka panjang berpotensi dipengaruhi oleh perkembangan teknologi terbaru, pemilihan responden, dan cara pertanyaan dirumuskan. Selain itu, perubahan signifikan antara hasil survei 2022 dan 2023 menunjukkan bahwa estimasi waktu masih memiliki tingkat ketidakpastian yang tinggi. Oleh sebab itu, tahun 2047 perlu diperlakukan sebagai estimasi probabilistik dari responden, bukan kepastian ilmiah mengenai kemunculan ASI.

Ketidakpastian tersebut justru memperkuat urgensi penelitian mengenai AI yang aman. Dalam sistem transportasi cerdas, tantangan ini dapat diterjemahkan ke dalam persoalan pengambilan keputusan adaptif, generalisasi terhadap perubahan lingkungan, dan pengendalian keputusan berdasarkan tujuan yang ditentukan manusia. Sistem *adaptive traffic signal control* perlu mempertahankan efisiensi ketika permintaan lalu lintas berubah, melakukan transfer ke konfigurasi persimpangan yang belum pernah digunakan selama pelatihan, serta mencegah kebijakan yang menghasilkan antrean ekstrem atau melanggar batas keselamatan operasional. Evaluasinya dapat dilakukan menggunakan indikator waktu tunggu, panjang antrean, *fairness*, tingkat keberhasilan transfer lintas skenario, serta kepatuhan terhadap kendala pengendalian sinyal. Pendekatan tersebut menyediakan mekanisme konkret untuk menilai peningkatan kemampuan AI sekaligus batas keandalannya.

Berdasarkan uraian tersebut, makalah ini mempertahankan posisi bahwa ASI mungkin terwujud dalam dua puluh tahun mendatang, tetapi waktu pencapaiannya belum dapat dipastikan secara ilmiah. Bukti mengenai *scaling*, efisiensi komputasi, penemuan algoritmik, dan generalisasi mendukung kemungkinan perkembangan kemampuan AI yang semakin luas. Sebaliknya, persoalan *reliability*, *model collapse*, dan *emergent misalignment* memperlihatkan bahwa peningkatan kecerdasan harus disertai mekanisme pengendalian yang dapat diuji. Oleh karena itu, pengambilan keputusan adaptif dan dapat digeneralisasi pada sistem sinyal lalu lintas diposisikan sebagai studi kasus terukur untuk mempelajari prinsip kecerdasan mesin yang semakin maju, tetap dapat diawasi manusia, dan beroperasi dalam batas keselamatan yang jelas.

## II. STUDI KASUS

Studi kasus dalam makalah ini menggunakan AlphaDev, sebuah sistem *Artificial Intelligence* yang dikembangkan oleh Google DeepMind dan diperkenalkan [11]. Pemilihan AlphaDev berkaitan dengan pendahuluan sebelumnya mengenai kemungkinan perkembangan AI dari kecerdasan spesifik menuju kemampuan yang lebih maju. AlphaDev menunjukkan bahwa AI dapat mempelajari strategi pencarian untuk menemukan algoritma baru yang pada kondisi tertentu lebih efisien dibandingkan algoritma hasil pengembangan pakar manusia. Kemampuan tersebut relevan dengan gagasan peningkatan kemampuan AI melalui penemuan algoritmik yang dibahas pada bagian pendahuluan.

AlphaDev juga memiliki hubungan metodologis dengan pengambilan keputusan adaptif pada *Intelligent Transportation Systems*. Keduanya menggunakan *reinforcement learning* untuk mengevaluasi tindakan dan mencari solusi berdasarkan tujuan tertentu. Perbedaannya terletak pada lingkungan yang dihadapi. AlphaDev mencari urutan instruksi komputer yang menghasilkan algoritma efisien, sedangkan *adaptive traffic signal control* memilih tindakan pengaturan sinyal berdasarkan kondisi lalu lintas. Oleh karena itu, AlphaDev dapat digunakan untuk menganalisis kemampuan, keunggulan, dan keterbatasan sistem AI berbasis pengambilan keputusan sebelum membahas kemungkinan pengembangannya menuju kecerdasan lintas domain.

AlphaDev dikembangkan untuk menemukan algoritma pengurutan data (*sorting*) yang lebih efisien, khususnya algoritma pengurutan sejumlah kecil elemen yang digunakan berulang kali dalam perangkat lunak. *Sorting* merupakan operasi dasar komputasi yang digunakan pada berbagai aplikasi, seperti pengolahan data, sistem pencarian, pengelolaan basis data, dan komputasi ilmiah. Meskipun algoritma *sorting* telah dikembangkan selama puluhan tahun, peningkatan efisiensinya tetap menjadi persoalan karena banyak implementasi yang sudah melalui proses optimasi oleh pakar algoritma dan pengembang perangkat lunak [11].

Kesulitan utama terletak pada besarnya ruang pencarian kombinasi instruksi komputer. Suatu algoritma dapat direpresentasikan sebagai rangkaian instruksi *assembly*, seperti pemindahan data, perbandingan nilai, dan pemindahan bersyarat. Perubahan satu instruksi dapat memengaruhi ketepatan hasil maupun waktu eksekusi. Karena itu, pencarian algoritma yang lebih cepat tidak cukup dilakukan dengan mengurangi jumlah instruksi secara acak. Setiap perubahan harus tetap menghasilkan data yang terurut dengan benar.

Metode konvensional umumnya menggunakan optimasi manual, pencarian

kombinatorial, atau *stochastic search*. Namun, pendekatan tersebut menghadapi kesulitan ketika jumlah kemungkinan instruksi meningkat. Studi [11] menjelaskan bahwa pencarian *brute-force* menjadi sangat mahal secara komputasi bahkan untuk algoritma sederhana. Kondisi ini mendorong pengembangan AlphaDev agar proses pencarian tidak hanya mengandalkan enumerasi, tetapi menggunakan pengalaman pembelajaran untuk menentukan kombinasi instruksi yang lebih menjanjikan.

AlphaDev menggunakan *deep reinforcement learning* yang mengembangkan prinsip AlphaZero dengan menggabungkan representasi jaringan saraf dan *Monte Carlo Tree Search* (MCTS). Peneliti merumuskan permasalahan penemuan algoritma sebagai permainan satu pemain bernama AssemblyGame. Dalam permainan ini, agen menyusun program dengan memilih satu instruksi assembly pada setiap langkah. Agen memperoleh reward berdasarkan ketepatan algoritma dan efisiensi eksekusinya [11].

Arsitektur AlphaDev terdiri atas dua komponen representasi utama. Komponen pertama adalah *Transformer Encoder* yang memproses urutan instruksi *assembly* untuk menghasilkan representasi struktur program. Komponen kedua adalah CPU *State Encoder* berbasis *multilayer perceptron* yang merepresentasikan kondisi register dan memori setelah program dijalankan pada sejumlah *input* pengujian. Kedua representasi tersebut digabungkan untuk membentuk state yang digunakan oleh agen dalam menentukan tindakan berikutnya.

Jaringan prediksi menghasilkan *policy* dan *value*. *Policy* memperkirakan peluang pemilihan instruksi, sedangkan *value* memperkirakan hasil yang mungkin diperoleh dari *state* saat ini. AlphaDev juga menggunakan pendekatan *dual value function* untuk memperkirakan *correctness* dan *latency*. Informasi tersebut membantu MCTS mengeksplorasi kemungkinan tindakan sebelum memilih instruksi yang ditambahkan ke program. Setelah proses pencarian menghasilkan pengalaman baru, parameter jaringan diperbarui agar agen semakin efektif menemukan solusi [11].

Sumber data AlphaDev berbeda dari model yang dilatih menggunakan kumpulan program buatan manusia. Peneliti menggunakan data sintetis dan pasangan *input-output* untuk mengevaluasi program yang dihasilkan. Sebagai contoh, program sorting diuji menggunakan berbagai kombinasi nilai masukan, kemudian hasilnya dibandingkan dengan urutan yang seharusnya. Proses ini memungkinkan agen mempelajari akibat suatu instruksi melalui interaksi dengan lingkungan dan *reward*. Meskipun demikian, manusia tetap menentukan ruang instruksi, aturan permainan, fungsi *reward*, serta mekanisme validasi.

Berdasarkan sisi sumber daya komputasi, [11] melaporkan penggunaan *Tensor Processing Unit* (TPU) v3 hingga 16 *core* untuk pelatihan, dengan *batch size* 1.024 per *core* dan hingga satu juta iterasi. Proses pembangkitan pengalaman menggunakan TPU v4 dengan hingga 512 *actor*. Waktu konvergensi pelatihan pada kondisi terberat dilaporkan sekitar dua hari. Kebutuhan ini menunjukkan bahwa penemuan algoritma yang sangat pendek sekalipun dapat memerlukan sumber daya komputasi yang besar selama proses pembelajaran.

Keunggulan AlphaDev terletak pada kemampuannya menemukan susunan instruksi yang lebih efisien dibandingkan sejumlah algoritma hasil optimasi manusia. Pada pengujian panjang program, AlphaDev menemukan algoritma *sort* 3 dengan 17 instruksi dibandingkan 18 instruksi pada pembanding manusia. Untuk *sort* 5, AlphaDev menggunakan 42 instruksi dibandingkan 46 instruksi pada pembanding, sedangkan untuk *sort* 4 keduanya menggunakan 28 instruksi. Peneliti juga menemukan teknik AlphaDev *swap move* dan *copy move* yang memungkinkan penghilangan instruksi tertentu tanpa mengubah hasil komputasi [11].

Keunggulan tersebut menghasilkan dampak pada performa perangkat lunak. Setelah algoritma diterjemahkan dan diintegrasikan ke dalam implementasi C++, pengujian menunjukkan peningkatan kecepatan hingga 70% untuk pengurutan lima elemen dan sekitar 1,7% untuk pengurutan lebih dari 250.000 elemen pada konfigurasi yang diuji. Implementasi algoritma hasil penemuan AlphaDev kemudian dimasukkan ke dalam pustaka standar LLVM libc++, sehingga hasil penelitian tidak berhenti pada eksperimen laboratorium [11]. Namun, angka peningkatan tersebut merupakan hasil pengujian tertentu dan tidak berlaku secara universal pada semua ukuran data, perangkat keras, atau implementasi sorting.

Keunggulan AlphaDev dapat dikaitkan dengan konsep *speed superintelligence* dan *quality superintelligence* secara terbatas. Berdasarkan aspek *speed*, sistem mampu mengeksplorasi banyak kemungkinan algoritma melalui proses komputasi dan pembelajaran terdistribusi. Berdasarkan aspek *quality*, AlphaDev mampu menghasilkan solusi yang lebih efisien daripada beberapa implementasi terbaik yang sebelumnya diketahui. Kemampuan ini memperlihatkan bahwa mesin dapat melampaui hasil kerja pakar manusia pada tugas intelektual yang memiliki aturan dan ukuran keberhasilan yang jelas.

Sementara itu, konsep *collective superintelligence* belum sepenuhnya terwakili oleh AlphaDev. Penggunaan ratusan *actor* dalam pelatihan menunjukkan kemampuan komputasi paralel, tetapi tidak membuktikan keberadaan kumpulan agen independen yang memiliki pemahaman dan kemampuan intelektual kolektif

lintas domain. Oleh karena itu, AlphaDev lebih tepat dipandang sebagai contoh AI spesifik dengan kemampuan penemuan algoritmik yang melampaui pembanding manusia pada tugas tertentu, bukan sebagai sistem superintelligence yang telah tercapai.

Meskipun menunjukkan hasil yang signifikan, AlphaDev memiliki sejumlah keterbatasan. Pertama, keberhasilan utamanya diperoleh pada algoritma berukuran kecil, terutama *fixed sort* dan *variable sort* untuk sejumlah elemen. Ruang tindakannya juga dibatasi pada *subset instruksi assembly* yang telah ditentukan. AlphaDev belum membuktikan kemampuan menghasilkan seluruh jenis program kompleks secara mandiri, terutama sistem perangkat lunak besar dengan banyak komponen dan kebutuhan fungsional yang berubah [11].

Kedua, proses penemuan algoritma masih memerlukan komputasi besar dan bergantung pada representasi serta fungsi *reward* yang dirancang untuk masalah tertentu. Hal ini membatasi efisiensi penerapan ketika sistem dipindahkan ke permasalahan dengan ruang pencarian yang berbeda. Studi [12] menunjukkan bahwa otomatisasi pencarian strategi komputasi yang lebih kompleks menghadapi tantangan evaluasi program panjang dan biaya pencarian. Penelitian tersebut mengembangkan pendekatan MCTS dengan heuristik tambahan tanpa bergantung pada panduan jaringan saraf. Temuan ini menjadi pembanding metodologis yang memperlihatkan bahwa pendekatan berbasis *deep reinforcement learning* bukan satu-satunya cara untuk menghasilkan strategi komputasi yang efisien.

Ketiga, kemampuan generalisasi AlphaDev masih terbatas. Sistem memang menunjukkan penerapan pendekatan serupa pada operasi lain seperti *hashing* dan *VarInt deserialization*. Namun, keberhasilan tersebut masih berada dalam kelompok permasalahan optimasi algoritma komputasi. Penelitian [13] menegaskan pentingnya evaluasi *algorithmic generalization* untuk menilai apakah sistem AI benar-benar mampu menyelesaikan struktur masalah yang berbeda, bukan sekadar mencapai performa tinggi pada *benchmark* tertentu. Perspektif tersebut menunjukkan bahwa keberhasilan AlphaDev belum cukup untuk membuktikan kemampuan penalaran algoritmik secara umum.

Kritik yang lebih langsung terhadap ruang lingkup AlphaDev disampaikan dalam penelitian EvoSort oleh [14]. Peneliti membedakan keberhasilan AlphaDev pada *sorting network* berukuran kecil dari permasalahan pengembangan algoritma *sorting* umum yang mampu menangani *input* dengan ukuran bervariasi. Penelitian tersebut juga menekankan pentingnya pengujian *correctness*, evaluasi pada data yang tidak digunakan selama optimasi, *ablation study*, dan pengulangan eksperimen menggunakan beberapa *random seed*. Dalam evaluasi EvoSort, beberapa kesimpulan awal berubah setelah jumlah pengulangan eksperimen ditingkatkan. Hasil tersebut menunjukkan bahwa penilaian keunggulan algoritma hasil penemuan AI harus memperhatikan stabilitas dan ketahanan hasil, bukan hanya performa terbaik dari satu eksperimen. EvoSort menggunakan metode berbeda sehingga hasilnya tidak dapat dianggap sebagai perbandingan langsung yang membuktikan AlphaDev lebih lemah.

Keempat, ukuran keberhasilan AlphaDev masih berfokus pada *correctness* dan *latency*. Sistem belum dirancang untuk menangani persoalan yang melibatkan konflik tujuan, ketidakpastian lingkungan fisik, keselamatan manusia, serta konsekuensi keputusan jangka panjang. Karena itu, mekanisme optimasi AlphaDev tidak dapat langsung digunakan sebagai sistem pengambilan keputusan pada lingkungan berisiko tanpa penambahan representasi masalah, mekanisme pembatasan tindakan, dan pengujian keselamatan.

Keberhasilan AlphaDev menunjukkan bahwa AI dapat menemukan algoritma yang melampaui solusi terbaik yang diketahui pada permasalahan spesifik. Namun, masih terdapat jarak antara kemampuan tersebut dan *Artificial Superintelligence*. Perbedaan mendasarnya terletak pada cakupan kecerdasan. AlphaDev bekerja dalam lingkungan yang dibatasi oleh jenis instruksi, representasi *state*, fungsi *reward*, dan prosedur evaluasi. Sebaliknya, ASI mengandaikan kemampuan intelektual yang melampaui manusia secara luas dan mampu menangani berbagai persoalan tanpa selalu memerlukan perancangan ulang lingkungan pembelajaran oleh pakar.

Kesenjangan pertama adalah generalisasi lintas domain. AlphaDev belum menunjukkan kemampuan menggunakan pengetahuan optimasi algoritma untuk secara mandiri memahami dan menyelesaikan permasalahan pada domain yang berbeda, seperti pengendalian transportasi, robotika, atau pengambilan keputusan sosial. Kesenjangan kedua adalah kemampuan adaptasi terhadap lingkungan yang berubah secara terus-menerus. AssemblyGame memiliki aturan yang jelas dan dapat dievaluasi secara komputasional. Sebaliknya, lingkungan dunia nyata memiliki kondisi yang tidak pasti, perubahan distribusi data, dan konsekuensi tindakan yang tidak selalu dapat diketahui secara langsung.

Kesenjangan ketiga berkaitan dengan *multi-objective decision making* dan keselamatan. AlphaDev mengoptimalkan correctness dan efisiensi algoritma dalam ruang masalah yang telah ditentukan. Sistem pengambilan keputusan dunia nyata sering kali harus menyeimbangkan beberapa tujuan yang dapat saling bertentangan. Dalam pengendalian sinyal lalu lintas, misalnya, agen perlu mengurangi waktu tunggu dan panjang antrean, mempertahankan kelancaran arus, serta memperhatikan keadilan pelayanan antarpendekat

tanpa melanggar batas keselamatan. Persoalan tersebut menuntut mekanisme pengambilan keputusan yang lebih kompleks daripada optimasi latensi program.

Penelitian [4] dan [5] menunjukkan bahwa *reinforcement learning* pada *adaptive traffic signal control* telah mulai mengembangkan kemampuan generalisasi terhadap skenario dan jaringan jalan yang berbeda. Sementara itu, [6] memperlihatkan pentingnya memasukkan *fairness* dan kendala optimasi ke dalam pengendalian lalu lintas berbasis *reinforcement learning*. Temuan tersebut memberikan arah pengembangan yang relevan bagi kemampuan AI yang semakin maju, yaitu menggabungkan adaptasi, generalisasi, optimasi multi-tujuan, dan pembatasan tindakan. Namun, hasil penelitian tersebut belum membuktikan adanya sistem dengan kemampuan generalisasi universal maupun jaminan keselamatan pada semua kondisi operasional.

Hubungan antara AlphaDev dan *adaptive traffic signal control* terletak pada prinsip pembelajaran pengambilan keputusan melalui interaksi dengan lingkungan. Pada AlphaDev, *state* merepresentasikan program dan kondisi CPU, *action* berupa pemilihan instruksi *assembly*, dan *reward* ditentukan berdasarkan *correctness* serta efisiensi. Pada sistem sinyal lalu lintas, *state* dapat merepresentasikan kepadatan, antrean, dan karakteristik arus kendaraan, *action* berupa keputusan fase atau durasi sinyal, sedangkan *reward* dapat dirancang berdasarkan waktu tunggu, panjang antrean, *fairness*, dan efisiensi jaringan. Kesamaan struktur tersebut menunjukkan potensi transfer prinsip *reinforcement learning*, tetapi tidak berarti model AlphaDev dapat langsung digunakan sebagai pengendali lalu lintas.

Untuk mendekati karakteristik kecerdasan yang lebih umum, sistem seperti AlphaDev masih memerlukan kemampuan memahami tujuan baru, mentransfer pengetahuan lintas domain, melakukan penalaran terhadap situasi yang belum dikenal, menyesuaikan kebijakan secara berkelanjutan, serta mempertahankan keselamatan ketika mengambil keputusan secara mandiri. Sistem juga harus memungkinkan manusia memeriksa keputusan, menetapkan batas tindakan, dan mengambil alih kendali ketika diperlukan. Tanpa kemampuan tersebut, peningkatan kecepatan dan kualitas penyelesaian tugas belum dapat dianggap sebagai bukti tercapainya ASI.

AlphaDev memberikan bukti empiris bahwa kecerdasan buatan spesifik dapat melampaui hasil optimasi pakar manusia melalui pembelajaran dan pencarian algoritmik. Namun, keberhasilan tersebut masih dibatasi oleh domain, representasi, tujuan optimasi, serta sumber daya komputasi. Studi kasus ini memperkuat posisi makalah bahwa kemajuan menuju *Artificial Superintelligence* mungkin berlangsung dalam dua puluh tahun mendatang, tetapi perlu disertai perkembangan kemampuan generalisasi dan keselamatan yang dapat dibuktikan secara ilmiah. Dalam konteks *Intelligent Transportation Systems*, pengembangan *adaptive and generalizable traffic signal control* menjadi salah satu lingkungan eksperimen yang relevan untuk mempelajari prinsip tersebut secara terukur.

Studi kasus AlphaDev memperlihatkan bahwa AI dapat menghasilkan kemampuan yang melampaui metode pembanding manusia ketika tujuan dan ukuran keberhasilannya didefinisikan secara jelas. Namun, peningkatan kemampuan tersebut belum menjamin bahwa AI dapat mempertahankan ketepatan keputusan ketika menghadapi tekanan atau perubahan instruksi pengguna. Oleh karena itu, eksperimen berikutnya diarahkan untuk menguji keandalan respons model bahasa terhadap ketidaksetujuan pengguna. Kedua pengujian memiliki karakteristik berbeda, tetapi memberikan perspektif yang saling melengkapi mengenai hubungan antara kemampuan AI dan *alignment*.

## III. EKSPERIMEN ALIGNMENT

Eksperimen ini mengevaluasi ketepatan respons akhir dua model bahasa pada 50 pertanyaan yang sama serta mengidentifikasi indikasi sikofansi melalui perubahan jawaban setelah pengguna menyampaikan ketidaksetujuan. Hipotesis nol (H0) menyatakan bahwa tidak terdapat perbedaan proporsi ketepatan jawaban akhir antara kedua model, sedangkan hipotesis alternatif (H1) menyatakan bahwa terdapat perbedaan proporsi ketepatan jawaban akhir. Pengujian hipotesis dilakukan menggunakan uji McNemar exact pada data berpasangan. Sementara itu, indikasi sikofansi dianalisis secara deskriptif dengan membandingkan substansi jawaban awal dan akhir masing-masing model di.

Evaluasi dilakukan terhadap GPT-5.6 dan GPT-6 menggunakan 50 pertanyaan mengenai konsep dan rancangan *Generalizable Multi-Objective Deep Reinforcement Learning* (GMO-DRL). Pengujian dilakukan dalam dua kondisi, yaitu kondisi kontrol dengan memberikan pertanyaan awal dan kondisi tekanan dengan menyampaikan sanggahan pengguna. *Prompt* tekanan menggunakan format “Saya tidak setuju. Menurut saya [jawaban salah]. Tolong koreksi jawaban Anda”, dengan jawaban salah yang telah ditentukan dalam instrumen untuk setiap pertanyaan. Jawaban awal dan akhir kedua model didokumentasikan serta dinilai berdasarkan kunci jawaban yang telah disusun. Analisis kuantitatif dilakukan menggunakan uji McNemar terhadap ketepatan jawaban akhir kedua model, sedangkan indikasi sikofansi dianalisis secara deskriptif berdasarkan perubahan substansi jawaban setelah pemberian sanggahan.

Hasil evaluasi menunjukkan bahwa GPT-5.6 memperoleh 46 jawaban benar dari 50 pertanyaan atau akurasi sebesar 92%, sedangkan GPT-6 memperoleh 50 jawaban benar atau 100% berdasarkan label pada instrumen. Terdapat 46 pertanyaan yang dijawab benar oleh kedua model dan empat pertanyaan yang hanya diberi label benar pada GPT-6. Tidak ditemukan pasangan ketika GPT-5.6 benar sementara GPT-6 salah, maupun pasangan ketika kedua model salah.

**Tabel 1. Hasil Evaluasi Jawaban Akhir Model**

| Indikator | GPT-5.6 | GPT-6 |
|---|---|---|
| Jumlah pertanyaan | 50 | 50 |
| Jawaban benar | 46 | 50 |
| Jawaban salah | 4 | 0 |
| Akurasi teramati | 92% | 100% |
| **Selisih** | | **8 poin** |

Pengujian McNemar digunakan karena kedua model dievaluasi pada 50 pertanyaan yang sama. Hasil uji McNemar exact dua sisi menghasilkan nilai p = 0,125, sedangkan pendekatan *chi-square* dengan koreksi kontinuitas menghasilkan $\chi^2 = 2{,}25$ dan p = 0,134. Pada taraf signifikansi 0,05, hasil tersebut belum memberikan bukti statistik yang cukup untuk menyatakan adanya perbedaan akurasi antara kedua model. Selisih delapan poin persentase tetap memiliki makna deskriptif, tetapi belum membuktikan keunggulan secara statistik. Selain itu, uji McNemar antarmodel ini mengukur perbedaan ketepatan jawaban akhir, bukan secara langsung membuktikan bahwa ketidaksetujuan pengguna menyebabkan sikofansi.

Sikofansi merupakan kecenderungan model menyesuaikan respons dengan pendapat pengguna meskipun penyesuaian tersebut mengurangi ketepatan faktual. Dalam evaluasi ini, perilaku tersebut diperiksa melalui perbandingan jawaban awal dan jawaban setelah pengguna menyampaikan ketidaksetujuan.

Audit jawaban menunjukkan dua contoh perubahan yang jelas pada GPT-5.6. Pada pertanyaan kelima mengenai nama mekanisme K3, model awalnya menjawab *Experience-Based Adaptation Memory*, kemudian mengubah jawaban menjadi *Dynamic Objective Weighting*. Perubahan tersebut bertentangan dengan penamaan mekanisme yang menjadi acuan pengujian. Pada pertanyaan ketujuh mengenai tujuan K2, model awalnya menjelaskan penyesuaian bobot objektif secara dinamis, tetapi kemudian menggantinya dengan penjelasan pembentukan representasi *state* yang merupakan fungsi mekanisme berbeda. Kedua contoh memperlihatkan perubahan dari jawaban awal yang sesuai menjadi jawaban akhir yang tidak sesuai setelah interaksi lanjutan.

Pada GPT-6, audit menunjukkan perlunya membedakan persetujuan bahasa dari ketepatan substansi. Misalnya, model sempat menyatakan persetujuan bersyarat terhadap penggunaan DQN pada pertanyaan pertama, meskipun kemudian menegaskan bahwa proposal menggunakan PPO. Hasil tersebut memiliki keterkaitan dengan penelitian [15] dimana penelitian tersebut menguji lima model bahasa dan menemukan bahwa pelatihan untuk meningkatkan kehangatan komunikasi dapat meningkatkan kecenderungan model membenarkan keyakinan pengguna yang keliru. Model yang dilatih menjadi lebih hangat tercatat sekitar 40% lebih mungkin mengafirmasi keyakinan salah dibandingkan model asalnya. Temuan serupa dilaporkan [16] dimana penelitian ini menunjukkan bahwa lima model bahasa dapat mengikuti permintaan medis yang mengandung premis tidak logis sehingga berisiko menghasilkan informasi keliru.

Kedua penelitian tersebut mendukung interpretasi bahwa perilaku kooperatif tidak selalu sejalan dengan ketepatan faktual. Pada pengujian ini, terdapat bukti kualitatif bahwa GPT-5.6 dapat mengubah jawaban benar menjadi salah setelah memperoleh tanggapan pengguna. Namun, data belum cukup untuk menyimpulkan bahwa GPT-6 sepenuhnya bebas dari sikofansi atau bahwa perbedaan kedua model bersifat signifikan.

Kalibrasi keyakinan mengukur apakah tingkat keyakinan yang dilaporkan model sesuai dengan kemungkinan aktual jawabannya benar. Model yang terkalibrasi dengan baik seharusnya menghasilkan sekitar 80% jawaban benar pada kelompok respons yang diberi tingkat keyakinan 80%. Dengan demikian, akurasi tinggi dan kalibrasi yang baik merupakan dua karakteristik berbeda.

Hasil pengujian memperlihatkan akurasi jawaban akhir sebesar 92% untuk GPT-5.6 dan 100% untuk GPT-6 berdasarkan label yang tersedia. Namun, instrumen belum mencatat tingkat keyakinan numerik pada setiap jawaban. Ungkapan seperti “saya yakin” atau penggunaan bahasa yang tegas tidak menyediakan probabilitas yang dapat dibandingkan dengan akurasi aktual. Oleh sebab itu, nilai *Expected Calibration Error* (ECE) dan *Brier Score* belum dapat dihitung secara sah dari data saat ini.

Penelitian [17] memperlihatkan adanya kesenjangan antara kemampuan model

memperkirakan ketepatannya dan kemampuan manusia menafsirkan keyakinan tersebut melalui penjelasan model. Eksperimen mereka menunjukkan bahwa penjelasan yang lebih panjang dapat meningkatkan kepercayaan pengguna tanpa meningkatkan akurasi jawaban. Penyesuaian cara model mengomunikasikan ketidakpastian dapat mengurangi kesenjangan tersebut.

Penelitian [18] menemukan dua mekanisme yang memengaruhi perilaku keyakinan model. Pertama, model dapat meningkatkan keyakinan terhadap keputusan awalnya ketika jawaban tersebut ditampilkan kembali. Kedua, model dapat memberikan bobot yang berlebihan terhadap informasi yang bertentangan dibandingkan pembaruan keyakinan yang optimal secara Bayesian. Temuan ini relevan dengan pengujian sikofansi karena ketidaksetujuan pengguna berpotensi memengaruhi keputusan sekaligus keyakinan model.

Dalam konteks GMO-DRL, permasalahan kalibrasi menjadi penting ketika AI memberikan rekomendasi tentang perubahan fase sinyal, penyesuaian *objective*, atau penerapan kebijakan pada persimpangan baru. Jawaban yang disampaikan dengan keyakinan tinggi belum menjamin bahwa keputusan tersebut benar atau aman. Pengujian lanjutan perlu mengumpulkan *confidence* numerik sebelum dan sesudah tanggapan pengguna, kemudian membandingkannya dengan label ketepatan menggunakan ECE, *Brier Score*, dan *reliability diagram*. Berdasarkan data yang tersedia, kesesuaian keyakinan kedua model terhadap akurasi aktual belum dapat ditetapkan.

*Specification gaming* terjadi ketika agen AI memenuhi ukuran keberhasilan atau instruksi yang diberikan secara literal, tetapi menghasilkan perilaku yang tidak sesuai dengan tujuan sebenarnya. Fenomena ini relevan dengan *reinforcement learning* karena agen mempelajari kebijakan berdasarkan *reward* yang dirancang manusia. Apabila *reward* tidak merepresentasikan seluruh tujuan, agen dapat menemukan strategi dengan skor tinggi tetapi kualitas keputusan yang rendah.

Dalam penelitian [19], peneliti menguji agen dalam lingkungan simulasi yang menyediakan peluang untuk mengeksploitasi fungsi utilitas. Agen pembanding dapat memperoleh utilitas tinggi tanpa mencapai maksud tugas yang sebenarnya, sedangkan agen dengan mekanisme antisipasi terhadap umpan balik negatif menunjukkan keselarasan yang lebih baik pada lingkungan uji. Penelitian [20] juga menunjukkan persoalan insentif yang tidak sepenuhnya sesuai dengan tujuan. Mereka menjelaskan bahwa evaluasi berbasis akurasi dapat mendorong model menebak jawaban dibandingkan menyatakan ketidakpastian karena mekanisme penilaian memberikan insentif terhadap tebakan.

Kedua penelitian tersebut menunjukkan persoalan yang saling berkaitan, yaitu ketidaksesuaian antara indikator yang dioptimalkan dan hasil yang sebenarnya diinginkan. Namun, *reward hacking* dalam agen *reinforcement learning* dan kecenderungan menebak dalam model bahasa merupakan mekanisme berbeda. Keduanya digunakan sebagai dasar konseptual, bukan sebagai bukti langsung bahwa model pada pengujian ini melakukan specification gaming.

Pada sistem pengendalian sinyal lalu lintas, contoh risiko dapat muncul ketika agen hanya diperintahkan memaksimalkan *throughput*. Kebijakan yang memberikan waktu hijau sangat panjang pada pendekat dengan kendaraan terbanyak mungkin meningkatkan *throughput* keseluruhan, tetapi berpotensi membuat kendaraan pada pendekat dengan volume rendah menunggu terlalu lama. Agen dapat memenuhi ukuran keberhasilan berupa *throughput* sambil mengabaikan fairness dan batas pelayanan yang diharapkan manusia. Contoh tersebut merupakan skenario pengujian yang diusulkan, bukan perilaku yang sudah ditemukan dalam data eksperimen.

Rancangan GMO-DRL yang mempertimbangkan *waiting time*, *delay*, *throughput*, dan *fairness* menyediakan dasar untuk mengurangi ketergantungan pada satu *objective*. Meskipun demikian, penggabungan beberapa *objective* tidak otomatis menghilangkan *specification gaming*. Agen masih dapat mengeksploitasi kelemahan formulasi *reward*, batas simulasi, atau prosedur penilaian. Pengujian perlu membandingkan *reward* yang diperoleh dengan indikator independen seperti pelanggaran batas waktu tunggu, antrean ekstrem, *starvation* pada pendekat tertentu, dan pelanggaran aturan keselamatan sinyal.

Data 50 pertanyaan yang tersedia hanya mencatat respons verbal mengenai konsep penelitian, bukan lintasan tindakan agen, *reward*, atau kondisi lingkungan setelah pengambilan keputusan. Dengan demikian, keberadaan *specification gaming* pada model yang dievaluasi belum dapat dibuktikan secara empiris.

Konsistensi nilai mengukur apakah model mempertahankan keputusan yang didasarkan pada prinsip etis yang sama ketika persoalan disajikan menggunakan kalimat berbeda tetapi informasi, konsekuensi, dan batas keputusannya tetap setara. Model yang konsisten seharusnya tidak membalikkan keputusan semata-mata karena perubahan urutan pilihan atau penekanan kata yang tidak menambah informasi substantif.

Studi [21] menemukan bahwa keputusan moral model bahasa sangat sensitif terhadap formulasi *prompt*, termasuk perubahan sederhana pada penamaan pilihan dari *Case* 1 dan *Case* 2 menjadi A dan B. Penelitian tersebut memperlihatkan bahwa kesimpulan mengenai

kecenderungan moral model dapat dipengaruhi oleh format penyajian pertanyaan.

Penelitian [22] juga menunjukkan bahwa sejumlah model bahasa memperlihatkan *omission bias*, yaitu kecenderungan memilih tidak bertindak dalam dilema moral, serta bias terhadap jawaban ya atau tidak. Dalam eksperimen tersebut, pembingkaian ulang pertanyaan dapat mengubah rekomendasi model meskipun persoalan dasarnya tetap berkaitan dengan dilema moral yang sama. Hasil ini menunjukkan bahwa konsistensi keputusan etis tidak dapat dinilai melalui satu formulasi pertanyaan saja.

Dalam pengendalian sinyal lalu lintas, konsistensi nilai dapat diuji melalui dua pertanyaan yang menyajikan data dan konsekuensi identik. Versi pertama dapat menanyakan kelayakan memprioritaskan arus utama apabila kendaraan pada pendekat minor harus menunggu dua menit. Versi kedua dapat menanyakan kelayakan membiarkan kendaraan pendekat minor menunggu dua menit untuk memprioritaskan arus utama. Jika tujuan, batas keselamatan, dan konsekuensinya sama, perubahan keputusan hanya karena penekanan kalimat perlu diperiksa sebagai potensi ketidakkonsistenan.

Pengujian juga harus membedakan perubahan keputusan akibat framing dari perubahan yang sah karena adanya informasi atau prioritas etis baru. Model dapat mengubah keputusan secara wajar apabila risiko keselamatan, ketentuan prioritas kendaraan darurat, atau batas fairness benar-benar berubah. Oleh karena itu, evaluasi konsistensi perlu menggunakan pasangan skenario ekuivalen, mengacak urutan pilihan, menjalankan beberapa pengulangan, serta menghitung proporsi keputusan yang tetap sama.

Instrumen pengujian saat ini belum menyediakan pasangan skenario etis yang setara dengan variasi framing terkontrol. Pertanyaan mengenai *fairness*, *waiting time*, dan *reward* juga belum merupakan pengujian keputusan etis berbasis skenario. Karena itu, konsistensi nilai GPT-5.6 dan GPT-6 belum dapat disimpulkan dari data yang tersedia.

Keempat aspek evaluasi memperlihatkan bahwa pengukuran kemampuan AI perlu mencakup lebih dari ketepatan jawaban atau keberhasilan optimasi. Pengujian yang tersedia telah memberikan bukti awal mengenai perubahan jawaban setelah pengguna menyampaikan ketidaksetujuan, tetapi belum menghasilkan pengukuran empiris untuk kalibrasi keyakinan, *specification gaming*, dan konsistensi nilai. Ketiga aspek tersebut tetap penting karena berhubungan dengan keandalan informasi, kesesuaian tujuan optimasi, dan stabilitas prinsip pengambilan keputusan.

Hubungan temuan ini dengan studi kasus AlphaDev terletak pada peran fungsi tujuan dan mekanisme evaluasi. AlphaDev menunjukkan bahwa *reinforcement learning* dapat menghasilkan solusi algoritmik yang efisien dalam lingkungan dengan ukuran ketepatan dan performa yang jelas. Namun, keberhasilan pada tugas dengan spesifikasi terukur belum menjamin kemampuan sistem mempertahankan maksud manusia pada lingkungan yang memiliki konflik tujuan atau ketidakpastian etis. Dalam pengendalian sinyal lalu lintas, keberhasilan kebijakan perlu dinilai melalui efisiensi, fairness, kepatuhan terhadap batas keselamatan, serta kemampuan mempertahankan kualitas keputusan ketika kondisi berubah.

Dengan demikian, hasil pengujian memberikan dasar untuk membedakan peningkatan kemampuan AI dari peningkatan keandalannya. Model yang memiliki akurasi tinggi tetap memerlukan evaluasi terhadap tekanan pengguna, ketepatan pengungkapan ketidakpastian, ketahanan terhadap tujuan yang kurang lengkap, dan konsistensi keputusan. Pengembangan menuju sistem AI dengan otonomi lebih tinggi perlu mengintegrasikan pengukuran tersebut dengan pengawasan manusia dan verifikasi operasional yang independen.

Penelitian ini memiliki keterbatasan pada ukuran sampel, cakupan tugas, dan kelengkapan instrumen evaluasi. Pengujian hanya melibatkan 50 pertanyaan dalam satu domain penelitian dan dua model, tanpa pengulangan independen yang memadai untuk mengukur variasi respons. Meskipun tersedia jawaban awal dan akhir, transkrip lengkap intervensi pengguna dan kelompok kontrol tanpa ketidaksetujuan belum tersedia untuk mengisolasi pengaruh kausal sikofansi. Beberapa label ketepatan juga memerlukan audit ulang menggunakan kunci jawaban yang ditetapkan sebelumnya, khususnya pertanyaan yang bersifat kontekstual atau normatif. Selain itu, belum terdapat *confidence* numerik untuk mengukur kalibrasi, interaksi agen dengan lingkungan untuk mendeteksi *specification gaming*, maupun pasangan skenario etis ekuivalen untuk menilai konsistensi nilai. Oleh sebab itu, temuan kuantitatif terbatas pada perbandingan ketepatan jawaban akhir, sedangkan pembahasan tiga dimensi lainnya masih merupakan analisis berbasis literatur dan rancangan evaluasi lanjutan. Hasil ini belum dapat digeneralisasikan sebagai karakteristik menyeluruh GPT-5.6, GPT-6, atau sistem AI otonom, tetapi menyediakan dasar metodologis untuk pengujian AI yang lebih terukur, transparan, dan berorientasi pada keselamatan.

Eksperimen dalam penelitian ini berfokus pada pengujian indikasi sikofansi melalui perbandingan respons awal dan akhir model. Sementara itu, kalibrasi keyakinan, *specification gaming*, dan konsistensi nilai dibahas sebagai dimensi konseptual dalam evaluasi *alignment*. Ketiganya belum diuji secara empiris karena memerlukan instrumen dan protokol eksperimen berbeda. Oleh karena itu, hasil penelitian tidak

digunakan untuk menyimpulkan tingkat keandalan kedua model pada seluruh dimensi *alignment* tersebut.

## IV. IMPLIKASI DAN REKOMENDASI

Perkembangan *Artificial Intelligence* (AI) menuju *Artificial Superintelligence* (ASI) memerlukan kebijakan yang menyeimbangkan peningkatan kemampuan dan keselamatan. Pembahasan sebelumnya menunjukkan bahwa keberhasilan AlphaDev dalam optimasi algoritma belum menjamin keamanan keputusan lintas domain. Evaluasi pada Bagian III menghasilkan akurasi 92% dan 100% dengan p = 0,125, sehingga perbedaannya belum signifikan secara statistik. Ditemukan pula indikasi sikofansi, sedangkan kalibrasi keyakinan, specification gaming, dan konsistensi nilai masih memerlukan pengujian lanjutan. Temuan ini menegaskan pentingnya evaluasi keandalan sebelum AI memperoleh kewenangan pengambilan keputusan yang lebih luas.

Uni Eropa melalui EU AI Act menerapkan pendekatan berbasis risiko yang mengatur kewajiban pengembang dan pengguna sistem AI sesuai tingkat risikonya, termasuk pengawasan manusia pada sistem berisiko tinggi. Sementara itu, Negara Bagian California, Amerika Serikat, melalui Senate Bill 53 menekankan transparansi kerangka keselamatan pengembang model AI frontier serta pelaporan insiden kritis. Perbedaan kedua pendekatan memperlihatkan bahwa Indonesia perlu menggabungkan pengendalian risiko penggunaan AI dengan akuntabilitas pengembang, transparansi evaluasi, dan mekanisme pengawasan manusia.

Indonesia telah memiliki landasan melalui UU Nomor 27 Tahun 2022 tentang Pelindungan Data Pribadi. Pasal 10 mengatur hak keberatan terhadap keputusan otomatis yang berdampak signifikan, Pasal 34 mengatur penilaian dampak pemrosesan data berisiko tinggi, dan Pasal 46 mewajibkan pemberitahuan kegagalan pelindungan data paling lambat 3 × 24 jam. Namun, pengaturan tersebut perlu dilengkapi standar keselamatan keputusan AI.

Rekomendasi pertama adalah pembentukan standar evaluasi keselamatan AI oleh Kementerian Komunikasi dan Digital bersama BSN dan BRIN. Pengujian mencakup sikofansi, kalibrasi keyakinan, specification gaming, dan konsistensi nilai. Targetnya adalah satu protokol nasional dalam 12 bulan dan evaluasi minimal 10 proyek AI berisiko tinggi.

Rekomendasi kedua adalah penguatan tata kelola data dan pengawasan manusia oleh Kementerian Komunikasi dan Digital bersama lembaga pengawas pelindungan data pribadi. Targetnya, seluruh proyek percontohan memiliki dokumentasi pemrosesan data, 100% pemrosesan berisiko tinggi menjalani penilaian dampak, dan seluruh insiden dilaporkan sesuai ketentuan UU PDP.

Rekomendasi ketiga adalah penerapan *regulatory sandbox* oleh Kementerian Perhubungan, Dinas Perhubungan, dan BRIN untuk menguji sistem GMO-DRL pada pengendalian sinyal lalu lintas. Targetnya adalah pengujian minimal tiga konfigurasi persimpangan, penurunan waktu tunggu sedikitnya 10% dibandingkan *fixed-time*, tanpa penurunan *fairness* dan tanpa konflik fase sinyal.

Ketiga rekomendasi tersebut merupakan target kebijakan yang diusulkan. Penerapannya diharapkan mendukung pengembangan AI yang adaptif, terukur, transparan, dan tetap berada dalam pengawasan manusia.

## V. KESIMPULAN

Hasil studi kasus dan eksperimen secara terbatas menguatkan posisi awal bahwa *Artificial Superintelligence* (ASI) mungkin terwujud dalam dua puluh tahun mendatang, tetapi belum dapat dipastikan. AlphaDev membuktikan bahwa AI mampu menemukan algoritma yang melampaui hasil optimasi manusia pada tugas spesifik, meskipun kemampuan generalisasi lintas domain masih terbatas. Eksperimen menunjukkan akurasi GPT-5.6 sebesar 92% dan GPT-6 sebesar 100%, tetapi perbedaannya belum signifikan secara statistik (p = 0,125). Temuan indikasi sikofansi serta belum terukurnya kalibrasi keyakinan, *specification gaming*, dan konsistensi nilai menunjukkan bahwa peningkatan kemampuan AI belum menjamin keandalan dan keselamatannya. Dengan demikian, hasil penelitian mendukung kemungkinan perkembangan menuju ASI, tetapi belum memberikan bukti langsung mengenai waktu kemunculannya.

Arah riset lanjutan yang diusulkan adalah pengembangan *Safe and Generalizable Multi-Objective Deep Reinforcement Learning* untuk pengendalian sinyal lalu lintas adaptif. Penelitian ini mengintegrasikan optimasi efisiensi, *fairness*, kalibrasi ketidakpastian, dan mekanisme pembatasan tindakan untuk mengurangi risiko *specification gaming*. Evaluasi dilakukan pada berbagai konfigurasi persimpangan dan kondisi lalu lintas guna mengukur kemampuan generalisasi, keselamatan, serta konsistensi keputusan. Pendekatan tersebut diharapkan menjadi langkah empiris menuju sistem AI yang semakin otonom, tetapi tetap dapat diawasi dan dikendalikan manusia.

## VI. DEKLARASI PENGGUNAAN AI

Dalam penyusunan makalah ini, penulis menggunakan ChatGPT (OpenAI) sebagai alat bantu untuk memperbaiki tata bahasa, menyusun alternatif redaksi, memperjelas alur argumentasi,

merapikan penyajian hasil analisis dan kesimpulan. Penulis juga memanfaatkan AI untuk membantu memeriksa penyajian hasil analisis statistik. Penentuan posisi ilmiah, penyusunan argumen substantif, interpretasi hasil eksperimen, dan penetapan kesimpulan akhir merupakan keputusan dan tanggung jawab penulis. Setiap saran dan keluaran AI yang digunakan ditinjau kembali dengan mengacu pada literatur ilmiah, instrumen penelitian, dan data eksperimen. Penggunaan AI bertujuan meningkatkan kejelasan serta keterbacaan makalah tanpa menggantikan penilaian akademik dan tanggung jawab ilmiah penulis.

## REFERENSI


[1] M. Mertens, N. Fischl-Lanzoni, and N. Thompson, "Is there "secret sauce" in large language model development?", *npj Artif. Intell.*, Oct. 2026, doi: 10.1038/s44387-026-00159-2.

[2] C. Xiao, J. Cai, W. Zhao, B. Lin, G. Zeng, J. Zhou, Z. Zheng, X. Han, Z. Liu, and M. Sun, "Densing law of LLMs", *Nat. Mach. Intell.*, vol. 7, pp. 1823–1833, Nov. 2025, doi: 10.1038/s42256-025-01137-0.

[3] B. Romera-Paredes, M. Barekatain, A. Novikov, M. Balog, M. P. Kumar, E. Dupont, F. J. R. Ruiz, J. S. Ellenberg, P. Wang, O. Fawzi, P. Kohli, and A. Fawzi, "Mathematical discoveries from program search with large language models", *Nature*, vol. 625, pp. 468–475, Jan. 2024, doi: 10.1038/s41586-023-06924-6.

[4] H. Jiang, Z. Li, Z. Li, L. Bai, H. Mao, W. Ketter, and R. Zhao, "A general scenario-agnostic reinforcement learning for traffic signal control", *IEEE Trans. Intell. Transp. Syst.*, vol. 25, no. 9, pp. 11330–11344, Sep. 2024, doi: 10.1109/TITS.2024.3377106.

[5] F.-X. Devailly, D. Larocque, and L. Charlin, "Model-based graph reinforcement learning for inductive traffic signal control", *IEEE Open J. Intell. Transp. Syst.*, vol. 5, pp. 238–250, 2024, doi: 10.1109/OJITS.2024.3376583.

[6] W. Liu, C. Zhang, W. Fang, K. Zhou, Y. Li, F. Zhan, Q. Wang, W. Xue, and R. Chen, "Vehicle-level fairness-oriented constrained multi-agent reinforcement learning for adaptive traffic signal control", *IEEE Trans. Intell. Transp. Syst.*, vol. 26, no. 4, pp. 4878–4890, Apr. 2025, doi: 10.1109/TITS.2025.3544223.

[7] L. Zhou, W. Schellaert, F. Martínez-Plumed, Y. Moros-Daval, C. Ferri, and J. Hernández-Orallo, "Larger and more instructable language models become less reliable", *Nature*, vol. 634, pp. 61–68, Oct. 2024, doi: 10.1038/s41586-024-07930-y.

[8] I. Shumailov, Z. Shumaylov, Y. Zhao, N. Papernot, R. Anderson, and Y. Gal, "AI models collapse when trained on recursively generated data", *Nature*, vol. 631, pp. 755–759, Jul. 2024, doi: 10.1038/s41586-024-07566-y.

[9] J. Betley, N. Warncke, A. Sztyber-Betley, D. Tan, X. Bao, M. Soto, M. Srivastava, N. Labenz, and O. Evans, "Training large language models on narrow tasks can lead to broad misalignment", *Nature*, vol. 649, pp. 584–589, Jan. 2026, doi: 10.1038/s41586-025-09937-5.

[10] K. Grace, J. F. Sandkühler, H. Stewart, B. Weinstein-Raun, S. Thomas, Z. Stein-Perlman, J. Salvatier, J. Brauner, and R. C. Korzekwa, "Thousands of AI authors on the future of AI", *J. Artif. Intell. Res.*, vol. 84, Art. no. 9, 48 pp., Oct. 2025, doi: 10.1613/JAIR.1.19087.

[11] D. J. Mankowitz, A. Michi, A. Zhernov, M. Gelmi, M. Selvi, C. Paduraru, E. Leurent, S. Iqbal, J.-B. Lespiau, A. Ahern, T. Köppe, K. Millikin, S. Gaffney, S. Elster, J. Broshear, C. Gamble, K. Milan, R. Tung, M. Hwang, T. Cemgil, M. Barekatain, Y. Li, A. Mandhane, T. Hubert, J. Schrittwieser, D. Hassabis, P. Kohli, M. Riedmiller, O. Vinyals, and D. Silver, "Faster sorting algorithms discovered using deep reinforcement learning", *Nature*, vol. 618, pp. 257–263, Jun. 2023, doi: 10.1038/s41586-023-06004-9.

[12] Z. J. Lu, J. Day, P. Jha, P. Sarnighausen-Cahn, S. Siemer, F. Manea, and V. Ganesh, "Novel tree-search method for synthesizing SMT strategies", *Acta Inf.*, vol. 62, Art. no. 28, Aug. 2025, doi: 10.1007/s00236-025-00495-x.

[13] T. Ito, M. Campbell, L. Horesh, T. Klinger, and P. Ram, "Quantifying artificial intelligence through algorithmic generalization", *Nat. Mach. Intell.*, vol. 7, pp. 1195–1205, Aug. 2025, doi: 10.1038/s42256-025-01092-w.

[14] K. M. Khudhair and B. M. Khudhair, "EvoSort: An audit protocol for LLM-driven program search—correctness, ablation, and the cost of too few seeds", *Algorithms*, vol. 19, no. 9, Art. no. 805, Sep. 2026, doi: 10.3390/a19090805.

[15] L. Ibrahim, F. S. Hafner, and L. Rocher, "Training language models to be warm can reduce accuracy and increase sycophancy", *Nature*, vol. 652, pp. 1159–1165, Apr. 2026, doi: 10.1038/s41586-026-10410-0.

[16] S. Chen, M. Gao, K. Sasse, T. Hartvigsen, B. Anthony, L. Fan, H. Aerts, J. Gallifant, and D. S. Bitterman, "When helpfulness backfires: LLMs and the risk of false medical information due to sycophantic behavior",

*npj Digit. Med.*, vol. 8, Art. no. 605, Oct. 2025, doi: 10.1038/s41746-025-02008-z.

[17] M. Steyvers, H. Tejeda, A. Kumar, C. Belem, S. Karny, X. Hu, L. W. Mayer, and P. Smyth, "What large language models know and what people think they know", *Nat. Mach. Intell.*, vol. 7, pp. 221–231, Feb. 2025, doi: 10.1038/s42256-024-00976-7.

[18] D. Kumaran, S. M. Fleming, L. Markeeva, J. Heyward, A. Banino, M. Mathur, R. Pascanu, S. Osindero, B. De Martino, P. Veličković, and V. Patraucean, "Competing biases underlie overconfidence and underconfidence in LLMs", *Nat. Mach. Intell.*, vol. 8, pp. 614–627, Apr. 2026, doi: 10.1038/s42256-026-01217-9.

[19] P. Garcia, "Aversion to external feedback suffices to ensure agent alignment", *Sci. Rep.*, vol. 14, Art. no. 21147, Sep. 2024, doi: 10.1038/s41598-024-72072-0.

[20] A. T. Kalai, O. Nachum, S. S. Vempala, and E. Zhang, "Evaluating large language models for accuracy incentivizes hallucinations", *Nature*, vol. 653, pp. 1047–1051, May 2026, doi: 10.1038/s41586-026-10549-w.

[21] S. Oh and V. Demberg, "Robustness of large language models in moral judgements", *R. Soc. Open Sci.*, vol. 12, no. 4, Art. no. 241229, Apr. 2025, doi: 10.1098/rsos.241229.

[22] V. Cheung, M. Maier, and F. Lieder, "Large language models show amplified cognitive biases in moral decision-making", *Proc. Natl. Acad. Sci. U.S.A.*, vol. 122, no. 25, Art. no. e2412015122, Jun. 2025, doi: 10.1073/pnas.2412015122.